

PRIORITY-CONDITIONED RETENTION

A Controllable Middle-Layer Memory Circuit in Pretrained Mamba

Pretrained Mamba 속 제어 가능한 중간층 기억 회로 — 재학습 없는 Δ -게이트 개입

2026-1 AI 시스템 3조

정찬희(발표자) · 안예준 · 김수윤

빠르지만, 과거를 잘 잊는 Mamba

Mamba는 지금까지 읽은 내용을 **크기가 고정된 메모리 하나(hidden state)**에 압축한다. 덕분에 길이에 비례하는 $O(N)$ 속도로 빠르게 처리하지만, 그 대가로 **기억해서 다시 꺼내는 능력(recall)이 약하다** — 앞에서 본 특정 정보를 정확히 다시 못 꺼낸다.

기존 통념

저장 공간 부족. 메모리에 저장할 공간 자체가 모자라서 생기는 한계다. 고치기 어렵다.

우리의 반론

제어의 문제. 공간이 모자란 게 아니라, **무엇을 남길지 못 고르는 것**이 진짜 문제다. Mamba는 ‘중요한 것’이 아니라 그냥 ‘최근 것’만 남기기 때문이다. 이걸 고칠 수 있다.

Transformer의 KV Cache, Mamba에는 불가능

Transformer (토큰마다 칸이 있음)

- 중요도 기반 압축 패러다임 완성

KIVI · ZipCache · KVQuant · TurboQuant

- 토큰별 슬롯 + random access

중요한 정보에 메모리를 더 배분

- 성숙한 프론티어

덜 중요한 건 줄이거나 버림 (KV-Cache 압축)

Mamba (칸이 없음)

- 슬롯이 없다

모든 정보가 메모리 하나에 겹쳐서 저장됨

- 기본 정책 = recency decay

오래된 정보가 자동으로 빠르게 사라짐 (최신 위주)

- importance-tiered retention = 공백

특정 정보만 골라 줄이는 게 불가능

RESEARCH QUESTION

토큰별 슬롯이 없는 Mamba에서,
아키텍처를 고치지 않고 중요도 기반 용량 배분을
어떻게 달성할 것인가?

선행 연구

1

KV-캐시 압축

KIVI, ZipCache, KVQuant,
TurboQuant (ICLR'26)

슬롯 기반 중요도 비트 배분

2

SSM 용량 한계

Jelassi+ 'Repeat After Me'
(ICML'24),
Primacy/Recency

고정 상태의 copy/recall 바
운드

3

SSM recall 개선

Zoology / MQAR, Based,
Just Read Twice

우리 실험의 직접 비교 대상

4

‘무엇을 기억할까’ 연구

Titans, DeltaNet, TTT,
Mamba-2


대부분 베이스를 학습·재설
계

용량 압박을 만드는 MQAR

Multi-Query Associative Recall

- 무작위 단어로 Key-Value 구성
상식으로 찍는 것 방지 (단어 4,000개)
- N개 쌍 → Query Key → Value 예측
N을 키우면 메모리가 포화됨
- 전처리: 1토큰=1위치 정렬
조작할 위치를 정확히 지정하기 위함
- 부하 그리드 N=2...64
정답률 약 0.5인 N=32를 기준으로 선택

Base recall vs N (790m)



PCR: 재학습 없이 보존 정책 변경

△ 게이트 한 정보가 살아남는 정도는 그 뒤에 오는 토큰들의 감쇠가 결정한다. 기억하고 싶은 정보 뒤 쪽의 Δ 를 줄이면 감쇠가 느려져 그 정보가 오래 남는다. 모델은 전혀 안 바꾸고, 추론할 때만 조작한다.

①

추론 때 Δ 직접 조작

forward hook으로 보존 (수동 조작)

②

질문 기반 자동화

질문을 보고 무엇을 남길지 스스로 판단

③


회로 자동 탐색

어느 층을 조작할지 모델이 학습

왜 이 방법인가 아키텍처를 새로 설계하는 다른 연구와 달리, 이미 학습된 모델을 그대로 쓰면서 재학습 없이 활용하는 접근 방식이다. 비용이 거의 안 든다.

Δ 를 줄여 recall 통제

Dose-response (N=32, all layers)




세 가지 통제 확인

- **조절량** 0.8에서 0.53→0.73로 최고, 너무 줄이면(0.6 이하) 오히려 붕괴
- **위치 특정성** 타깃 뒤를 조작하면 0.73, 아무 위치나 조작하면 0.50 (위치가 중요)
- **방향성** 반대로 Δ 를 키우면 오히려 나빠짐 → 진짜 인과관계

L16~23: 적은 비용으로 기억을 되살리는 회로

Layer 그룹별 정답률 상승폭



16~23층만 조작

recall 0.67 ppl ×1.07

전체 층 조작

recall 0.73 ppl ×1.81

48층 중 8층만으로 거의 같은 효과 + 부작용(ppl) 거의 없음 → 기억 전담 '회로'가 따로 있다는 증거

한계

✕ **다른 모델** 더 큰 1.4b 모델에선 재현 안 됨 → 실험은 790m에만 해당

✕ **자연어** 여러 사실을 묻는 실제 문장에선 불안정, 오히려 성능이 떨어질 수 있음

✕ **양자화 시도** 특정 정보만 적은 비트로 줄이려 하면 정답률 급락

→ 이 한계가 오히려 우리 주장을 뒷받침한다.

중요도에 따른 차등 보존은 게이트 조절로는 되지만, 비트 줄이기로는 안 된다 — 칸 없는 메모리의 특성

향후 연구 계획

0	Stage 0	Probe (게이트)	메모리가 실제로 꼭 찾는지 측정 → 저장 문제인지 제어 문제인지 판별
1	Stage 1	Question-conditioned + auto-localizing 컨트롤러	모델은 그대로 두고 작은 컨트롤러만 학습 → 사람 개입 없이 자동화
2	Stage 2	Streaming + Belady	질문이 계속 들어오는 상황에서 최적 보존 대비 효율 측정
3	Stage 3	이론 정리·논문화	Transformer 압축과 Mamba 보존을 하나의 원리로 연결

요약

Mamba의 기억은 고정된 천장이 아니라,
특정 중간층이 담당하는, 우리가 ‘조절할 수 있는’ 능력

- 16~23층 회로 — 재학습 없이 적은 비용으로 Mamba capacity 향상 ($\text{ppl} \times 1.07$)
- Control-limited 구간 입증 — 저장 문제와 제어 문제를 측정으로 구분
- 낮은 부작용 — 국소 조작이라 언어 모델 품질 유지

A1 · 메커니즘

상태 갱신:

$$h_t = \bar{A}_t h_{t-1} + \bar{B}_t x_t, \quad \bar{A}_t = \exp(\Delta_t A), \quad A < 0$$

surviving contribution:

$$r_i = \prod_{\tau=i+1}^T \bar{A}_\tau$$

— token i가 질의 시점까지 살아남는 양

제약: $\Delta > 0 \Rightarrow \bar{A} < 1$ 이라 decay가 공유됨 → 항목별 독립 비트 배분 불가 (recency 편향은 구조 불변) → quantization 실패

A2 · 핵심 수치 (Mamba-790m)

실험	조건	결과
Base recall	N=32	0.53
Dose-response	og=0.8 (all layers)	0.53 → 0.73 (정점)
Specificity	downstream vs random	0.73 vs 0.50
Localization	L16-23 / L24-31	Δ +0.13 / +0.07
Surgical	L16-23 only	recall 0.67 · ppl $\times$ 1.07
전층 비교	all layers	recall 0.73 · ppl $\times$ 1.81

A3 · Negative results 상세

Cross-model (1.4b)

N=32 base 0.54에서 모든 Layer 그룹 $\Delta \leq 0 \rightarrow$ 회로 비재현. 790m은 base 0.65서도 +0.32.

자연어 전이

single-needle은 base 1.0(압박 無) 무의미
multi-fact는 L16-23 개입이 -0.07~-0.40. computation-bound는 해침.

Quantization 레버

A(target k-bit): 8b 0.53 $\rightarrow$ 4b 0.03 절벽.
B(저우선 k-bit): 4b에서 target 0.00 붕괴 = 재배분 아닌 오염.

Graded P1/P2/P3

단조로 보였으나 질의 위치와 교란 $\rightarrow$ 주장 불가, position-control 재실험 필요.

A4 · Baselines · 평가지표

- **Baselines**

vanilla Mamba(통제) · Just Read Twice(프롬프팅 recall) · global- Δ · position/param-matched

- **Offline optimal**

Belady-MIN (가장 늦게 쓰일 항목부터 eviction)

- **Retention Efficiency**

Recall_model / Recall_Belady — gap을 (정책 최적성)+(연속-state 구현) 2단 분해

- **통제**

shuffled-tag null · K 커리큘럼 · 시드 ≥ 3 + 에러바 · ppl guardrail

A5 · 재현성 · 환경

- **모델** — state-spaces/mamba-790m-hf (48 layers, fp32)
- **환경** — Colab T4. mamba-ssm/causal-conv1d 미설치 → slow path 강제(Δ 혹은 가능)
- **코드** — PCR_from_scratch.ipynb (로드→혹→Gate1→국소화→surgical→write-order→graded→quant)
- **probe** — pcr_stage0_probe.py (state effective-rank vs N)